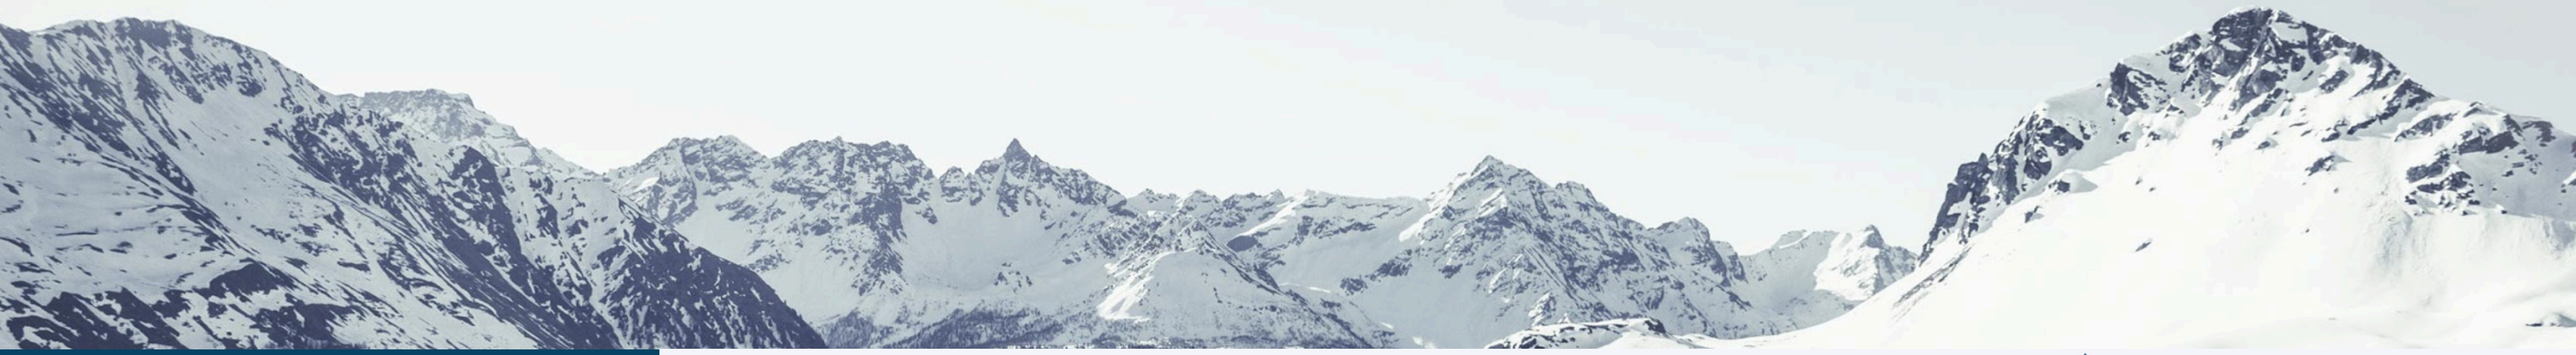
UNIVERSITAS
GADJAH MADA

Group Mini Project

Klasifikasi Diabetes pada Pima Indians Diabetes Dataset dengan Multilayer Perceptron

Anggota Kelompok:

1. Ananda Auliya Rahma (24/533691/PA/22608)
2. Aulia Fathus Tsani (24/534388/PA/22661)
3. Alifa Batrisyia Nariswari (24/535256/PA/22707)
4. Herlina Iin Nur Soleha (24/541333/PA/22962)



Jobdesk Anggota

Ananda Auliya Rahma	:	Eksplorasi dataset dan prapemrosesan (nilai 0 menjadi data kosong, imputasi median, standardisasi, split 80/20 stratified, 5-fold CV), serta baseline Logistic Regression, SVM, dan Random Forest
Aulia Fathus Tsani	:	Implementasi MLP di PyTorch, serta eksperimen arsitektur, fungsi aktivasi, dan regularisasi (dropout, weight decay, BatchNorm, class weight)
Alifa Batrisyia Nariswari	:	Eksperimen optimizer, learning rate, epoch, dan batch size, random search 40 kombinasi, serta pelatihan dan uji akhir model pada data uji
Herlina Iin Nur Soleha	:	Kode evaluasi (accuracy, precision, recall, F1, AUC), confusion matrix, kurva ROC, learning curve, permutation importance, dan 10 grafik hasil

Deskripsi Kasus: Prediksi Diabetes

Masalah: Diabetes sering baru terdeteksi setelah berkembang. Data klinis rutin seperti kadar glukosa, BMI, dan usia dapat dipakai untuk menyaring pasien berisiko lebih awal.

Tugas: Klasifikasi biner: pasien terdiagnosis diabetes (1) atau tidak (0), diprediksi dari 8 fitur klinis.

Tantangan: Data kecil, kelas tidak seimbang, dan banyak nilai kosong yang tercatat sebagai 0.

Metrik: ROC-AUC, F1, dan recall. Pasien positif yang terlewat lebih merugikan daripada alarm palsu, sehingga akurasi saja tidak cukup.

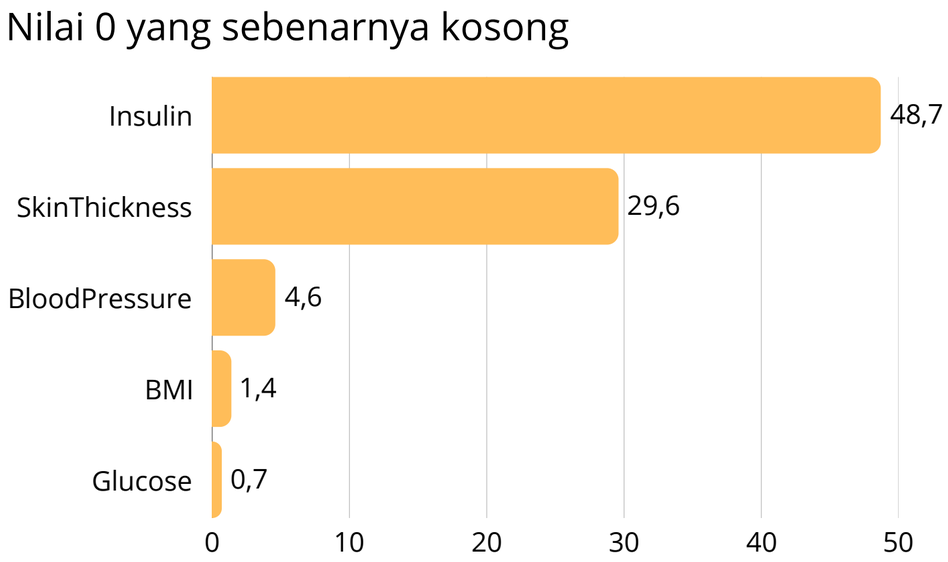
768 pasien dalam dataset

34,9% berlabel diabetes

8 fitur klinis sebagai input

Dataset dan Skema

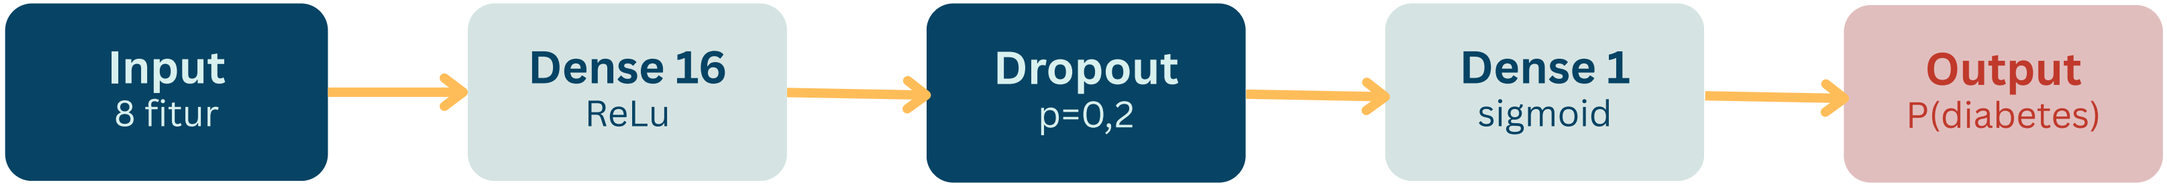
Nama Dataset	**:**	**Pima Indians Diabetes Database**
Link Dataset	:	*https://www.kaggle.com/datasets/mragpavank/diabetes*
Fitur	:	Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, Age.
Target	:	Outcome (0/1)



Skema Validasi

Split data menjadi 80/20, stratified: 614 latih, 154 uji → 5-fold CV stratified pada data latih untuk semua tuning → Preprocessing (median, standardisasi) dihitung di tiap fold

Arsitektur MLP



161 parameter terlatih (8×16+16 pada layer pertama, 16+1 pada output), cocok untuk 614 sampel latih.

Mengapa arsitektur ini cocok?

Data Kecil	Data Tabular	Bukti di Cross-Validation
Hanya 614 sampel latih, jadi 161 parameter cukup dan tidak menghafal data (risiko overfitting rendah)	Hanya 8 fitur numerik, satu hidden layer sudah cukup menangkap polanya.	Lebih dalam malah turun: AUC 0,848 (1 layer) vs 0,760 (4 layer).

Learning Strategy dan Parameter Tunning

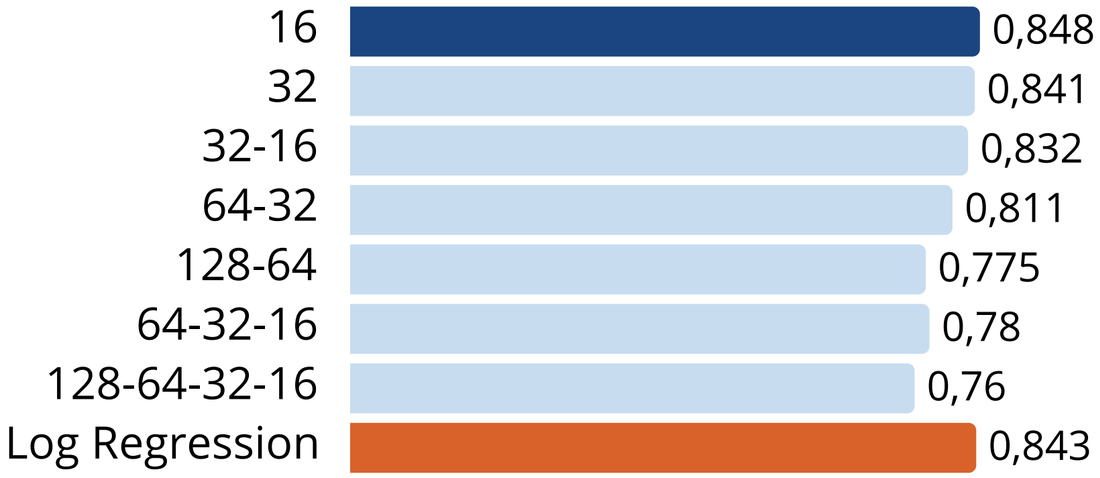
Konfigurasi terbaik:

Parameter	Nilai
Loss	BCE, pos_weight 1,87
Optimizer	RMSprop, lr 0,0005
Weight decay	0,0001
Batch size	64
Epoch	200
Dropout	0,2
Seed	42

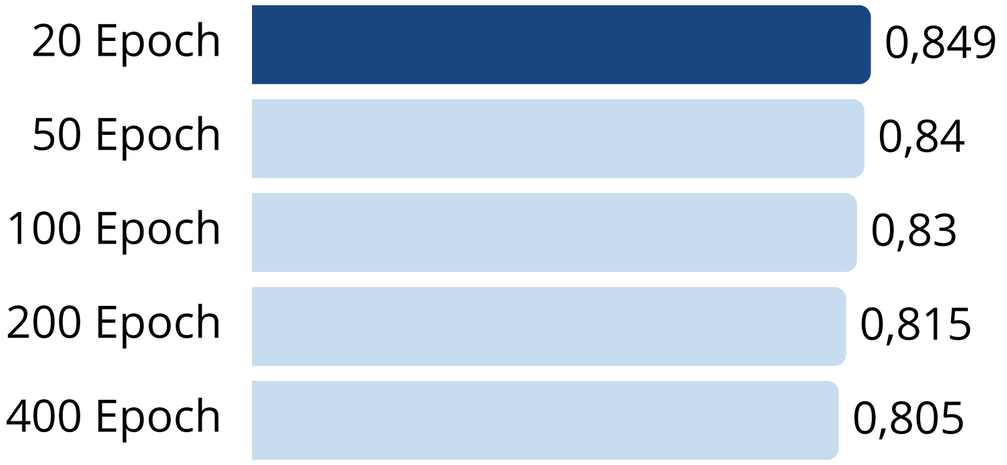
1. **Satu faktor per eksperimen.** Arsitektur, regulasi, optimizer, dan learning rate, jumlah epoch, serta batch size.
2. **Random search 40 kombinasi.** Semua faktor diacak bersama dalam satu ruang pencarian
3. **Seleksi dengan 5-fold Cross Validation.** Kriteria rata-rata ROC-AUC, total 78 konfigurasi atau 390 kali pelatihan.
4. **Uji akhir satu kali.** Model terbaik dilatih ulang pada seluruh data latih (seed 42) dan diuji pada data uji yang belum pernah dipakai.

Hasil Eksperimen (1/3)

AUC 5-Fold CV Menurut Arsitektur



AUC 5-Fold CV Menurut Jumlah Epoch



Makin dalam dan makin lama dilatih, **AUC semakin turun.** Data latih = 614 sampel

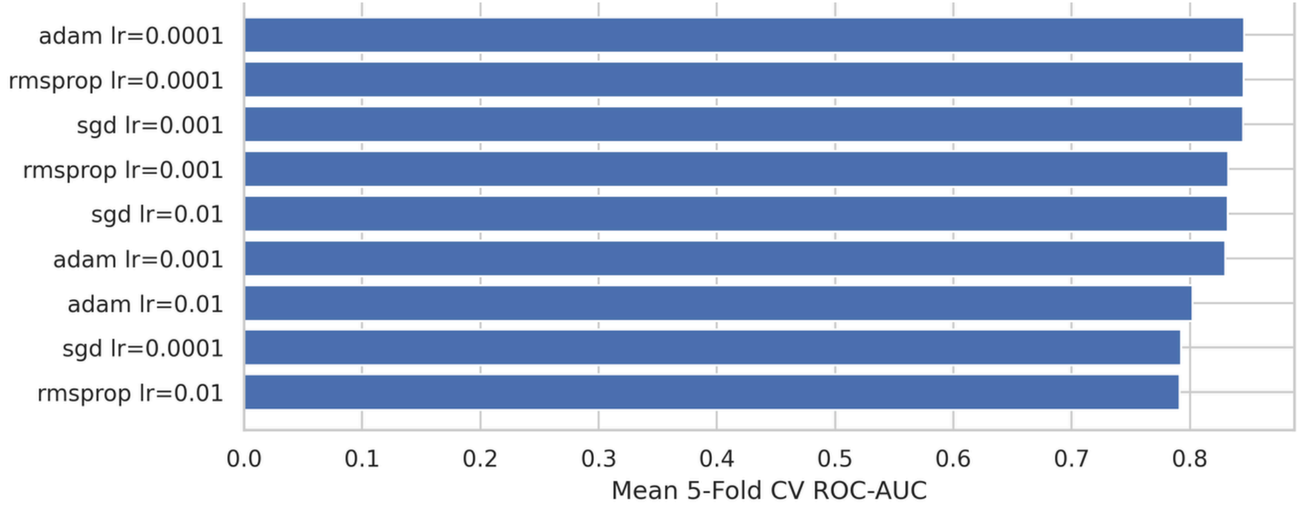
Hasil Eksperimen (2/3)

Teknik Regularisasi

Teknik	AUC	Recall
Tanpa Regularisasi	0,811	0,626
Dropout 0,2	0,83	0,622
Dropout 0,4	0,842	0,607
Weight decay 0,001	0,818	0,621
Batch Norm	0,792	0,635
BN + dropout 0,3	0,837	0,626
Class weight	0,81	0,696

- **Dropout 0,4** menaikkan AUC dari 0,811 ke 0,842; BatchNorm menurunkannya ke 0,792
- **Learning rate kecil** lebih stabil, SGD 0,0001 underfit (recall 0,014)
- **Class weight** menaikkan recall ke 0,696 tanpa mengubah AUC secara berarti

AUC Menurut Oprimizer dan Learning Rate



Optimizer	0,01	0,001	0,0001
Adam	0,802	0,83	0,846
SGD	0,832	0,845	0,793
RMSprop	0,791	0,832	0,846

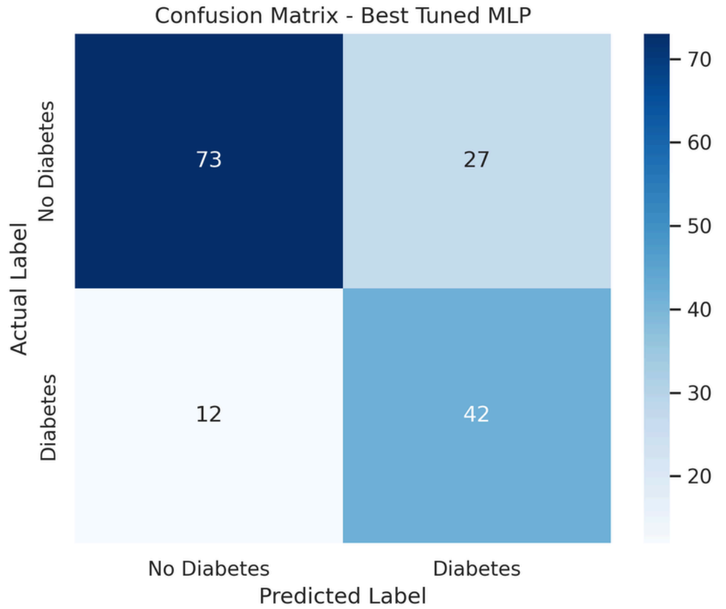
Hasil Eksperimen (3/3)

Pembanding pada 5-Fold CV (614 data training)

Model (5-Fold CV)	AUC	F1	Recall
Logistic Regression	0,843	0,655	0,575
SVM (RBF)	0,833	0,637	0,57
Random Forest	0,818	0,631	0,584
MLP terbaik	**0,853**	**0,687**	**0,762**

Nilai berwarna Hijau = MLP terbaik hasil random search 40 kandidat. Angka CV cenderung optimistis karena konfigurasi dipilih dari CV yang sama.

Uji akhir MLP Terbaik (154 sample)



Accuracy = 0,747; F1 = 0,683; Recall = 0,778;
Precision = 0,609; AUC = 0,809

MLP terbaik menangkap 42 dari 54 pasien diabetes, AUC uji 0,809 setara baseline Logistic Regression 0,813.

Kesimpulan

Model kecil terbaik

MLP satu layer 16 unit mencapai AUC CV 0,848; jaringan 4 layer hanya 0,760. Data 614 sampel tidak cukup untuk model dalam.

AUC setara baseline

Pada data uji, AUC MLP 0,809 dan Logistic Regression 0,813. Selisih ini jauh di bawah variasi antar-fold (SD sekitar 0,02).

Recall MLP lebih tinggi.

Recall 0,778 dibandingkan 0,500 pada Logistic Regression. F1-score MLP 0,683, dengan precision 0,609.

Glukosa paling berpengaruh

Mengacak Glucose menurunkan AUC uji 0,13, BMI 0,03, dan fitur lain di bawah 0,02.

Keterbatasan: satu split uji (154 sampel), satu seed, dan konfigurasi terbaik dipilih dari 40 kandidat, sehingga AUC CV 0,853 cenderung optimistis.

Notebook dan Dataset

Notebook

https://colab.research.google.com/drive/DeepLearningGroupMiniProject

Dataset

Pima Indians Diabetes Dataset (NIDDK/UCI)

https://www.kaggle.com/datasets/mragpavank/diabetes

Github

https://github.com/auliafathustsani/Deep-Learning-Diabetes-Prediction

Daftar Pustaka

1. Afiahayati. (2026). Single Layer Perceptron to Multi Layer Perceptron [Bahan ajar/Slide kuliah]. Departemen Ilmu Komputer dan Elektronika, FMIPA, Universitas Gadjah Mada.

2. Smith, J. W., Everhart, J. E., Dickson, W. C., Knowler, W. C., & Johannes, R. S. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proceedings of the Annual Symposium on Computer Application in Medical Care, 261–265.

3. Pavan Kumar D. (2020). Pima Indians Diabetes Database [Data set]. Kaggle. https://www.kaggle.com/datasets/mragpavank/diabetes

4. Srivastava, N., et al. (2014). Dropout: A simple way to prevent neural networks from overfitting. Journal of Machine Learning Research, 15, 1929–1958.